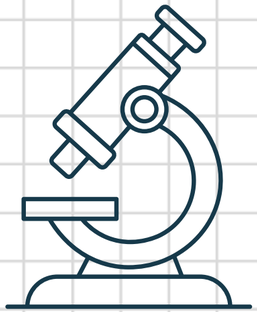
Estrutura Escolar Contexto Municipal Desempenho no ENEM (2014 - 2023)

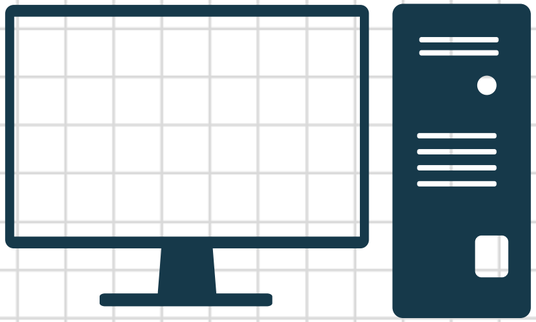


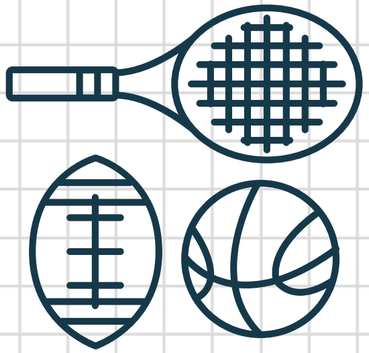
Thomas Jeferson Caldeira
Topicos Especiais em Banco de Dados II
Prof. Antônio Almeida de Barros Junior

Pergunta central

Em que medida a infraestrutura das escolas e o contexto econômico do município explicam as diferenças de desempenho no ENEM?







Justificativa da escolha do tema

A rede estadual concentra 63,3% dos concluintes analisados em 2023;
≃ 70% rede pública;

Desigualdades entre redes, regiões e municípios são um problema persistente

As três bases são públicas, oficiais, anuais e cobrem todos os municípios do país

Visão Geral das Bases de Dados Selecionadas



Microdados

Censo Escolar (inep)

2014 - 2023

CSV, anual,

217.625 escolas

408 variáveis em 2023

Microdados do Enem (Inep)

2014 - 2023

csv, anual

3,933,955 registros

76 variaveis em 2023



59,019,047



PIB dos Municípios

(IBGE/SIDRA)

2014–2023

55.700 registros

(5.570 × 10 anos)

Principais Variáveis

E
N
E
M

- notas das 5 provas
- presença
- situação de conclusão
- perfil do participante (sexo, cor/raça, faixa etária)
- questionário (renda, escolaridade dos pais)
- município
- rede e localização da escola

Principais Variáveis

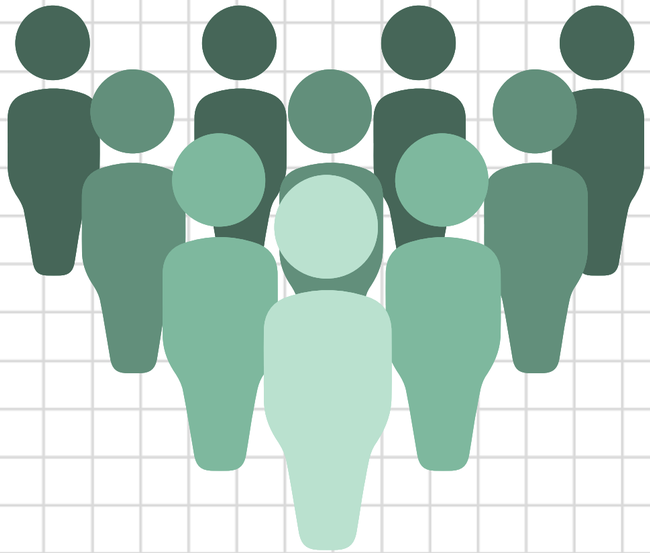
CENSO

- biblioteca
- laboratórios de informática e ciências
- quadra
- internet
- matrículas e docentes do EM
- rede
- localização

Principais Variáveis

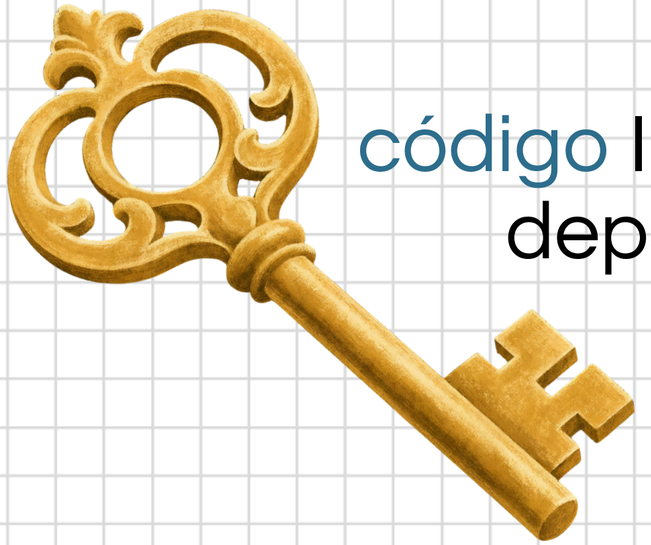
IBGE

- PIB a preços correntes
- população, a incorporar



Estratégia de integração

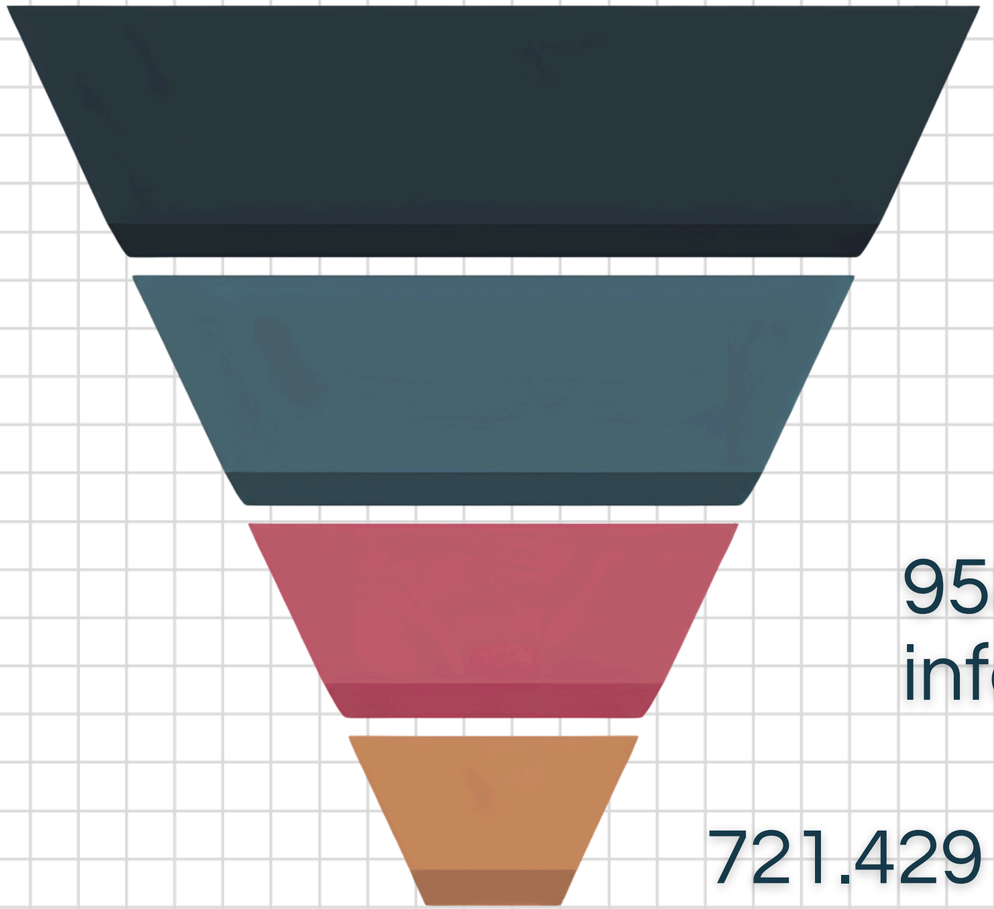
ENEM ↔ Censo ↔ PIB



código IBGE do município (7 dígitos)
dependência administrativa
localização + ano

Resultado: 99,7% dos participantes encontram a sua chave no Censo, e 100% dos municípios casam com o PIB

Amostra analisada



3.933.955 inscritos

1.401.164 concluintes

958.506 com a escola informada (68,4%)

721.429 presentes nas 4 provas objetivas

Qualidade dos dados: Enem

75,6% de nulos nos campos de escola.

Concluintes ⬇

31,6% não têm a escola informada.

2020 é um ano atípico por causa da pandemia

117.829 redações com nota zero

Qualidade dos dados: PIB e Censo

Censo sem nulos nas variáveis de infraestrutura

Internet água potável e banheiro quase não variam entre escolas $\simeq$ 98%

valores deflacionados pelo IPCA a preços de 2023

per capita pendente

A rede municipal tem só 0,8% dos participantes

KPIs

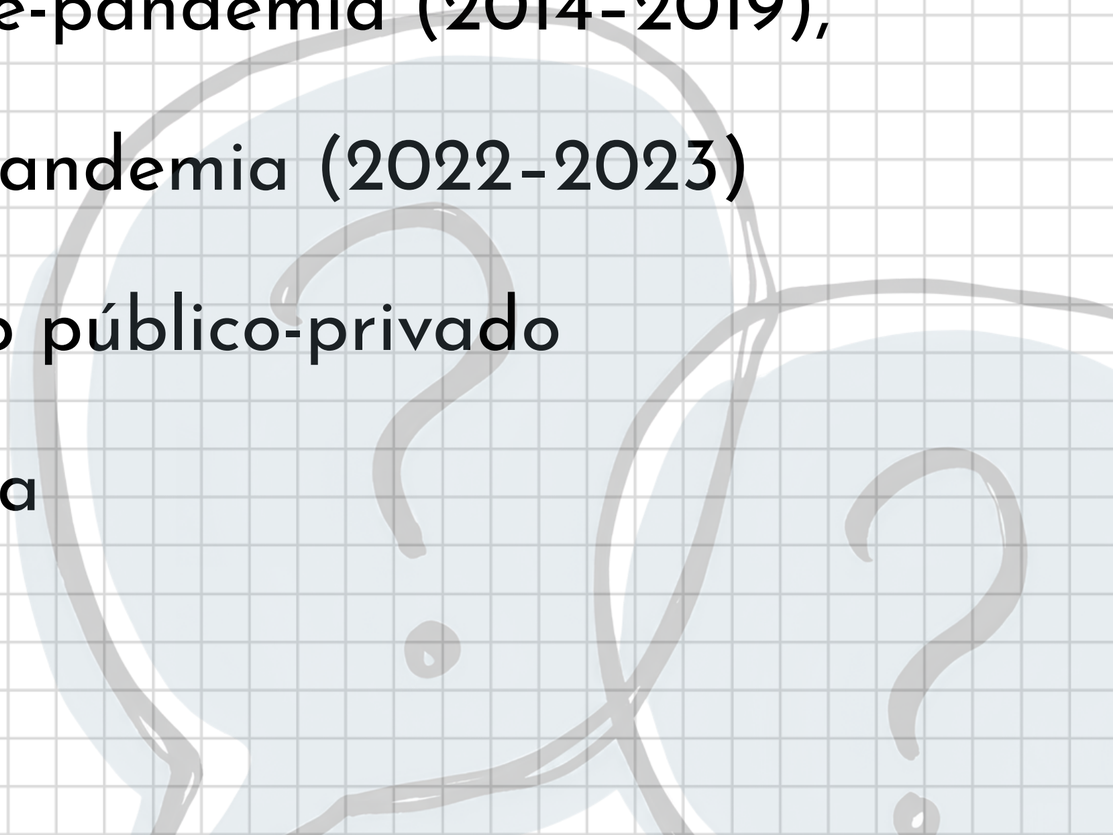
Nome	Finalidade	Cálculo
Nota média geral	Mede o desempenho geral dos participantes	Média das 5 notas (CN, CH, LC, MT, Redação) por grupo
Nota média por área	Compara o desempenho entre as áreas do conhecimento	Média de CN, CH, LC, MT e Redação, calculada separadamente
Taxa de presença	Mede o engajamento dos concluintes inscritos	Concluintes presentes nas 4 provas ÷ concluintes inscritos
% de alto desempenho	Identifica participantes com desempenho de destaque	Participantes com média ≥ 600 ÷ participantes presentes
Índice de Infraestrutura Escolar (IIE)	Avalia a qualidade da infraestrutura das escolas	Média de biblioteca, lab. de informática, lab. de ciências e quadra (0 a 1), agregada por grupo
Razão aluno/docente	Mede a relação de atendimento por professor	QT_MAT_MED ÷ QT_DOC_MED
Gap público-privado	Mede a disparidade de desempenho entre redes	Média da rede privada − média da rede pública, no mesmo município e ano
PIB per capita real	Mede a capacidade econômica per capita do município	PIB deflacionado ÷ população

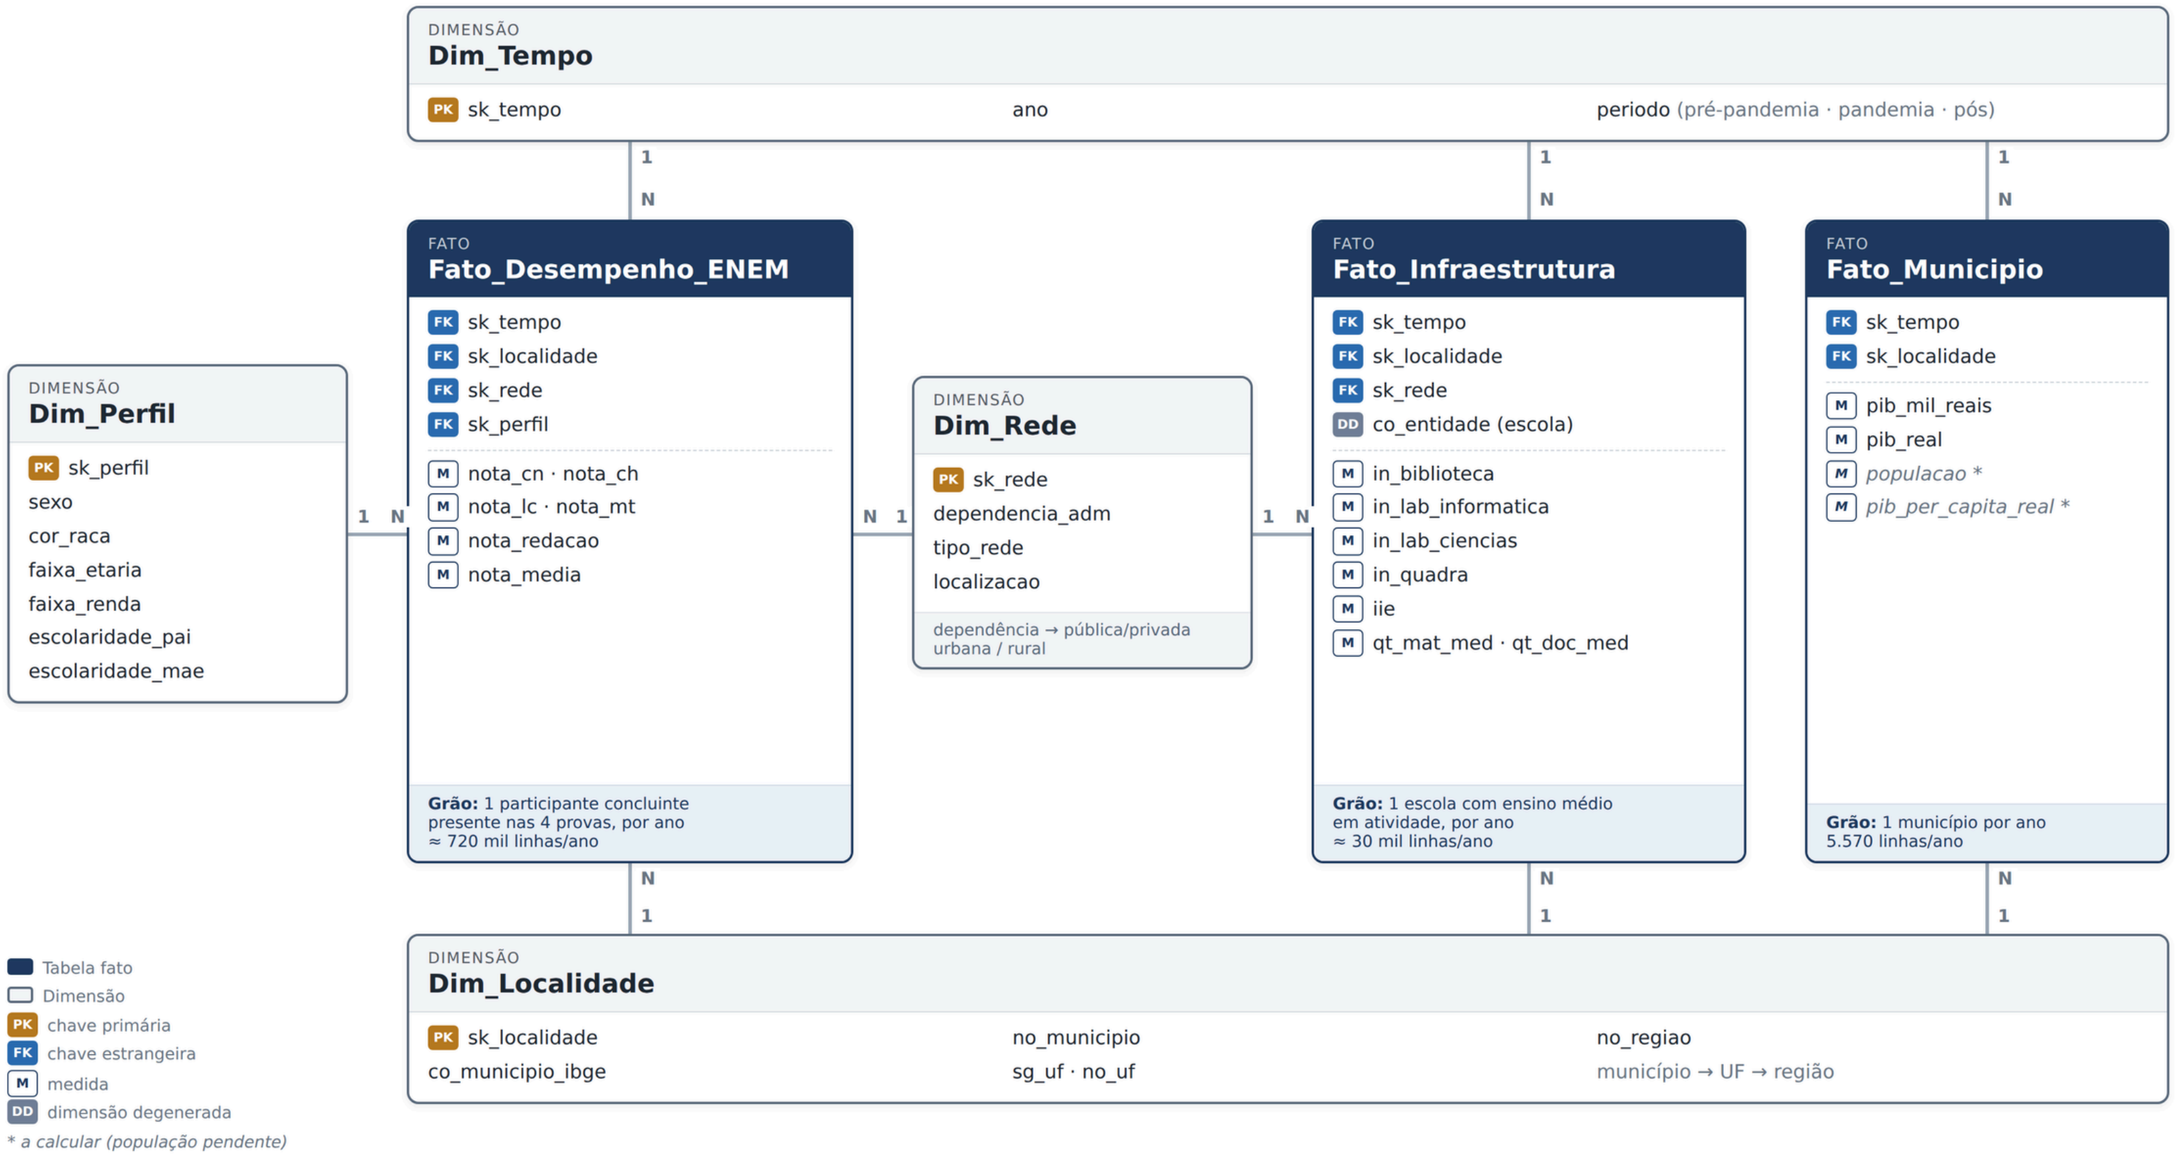
Perguntas analíticas

- Municípios e redes com maior IIE tem desempenho maior no ENEM?
- O gap público-privado diminuiu entre 2014 e 2023? Em quais UFs?
- A relação entre infraestrutura e nota se mantém quando se compara municípios com PIB per capita semelhante?
- Qual o efeito da pandemia (2020–2021) na presença e nas notas, por rede?
- Como a infraestrutura das escolas de EM evoluiu na década?

Análises temporais

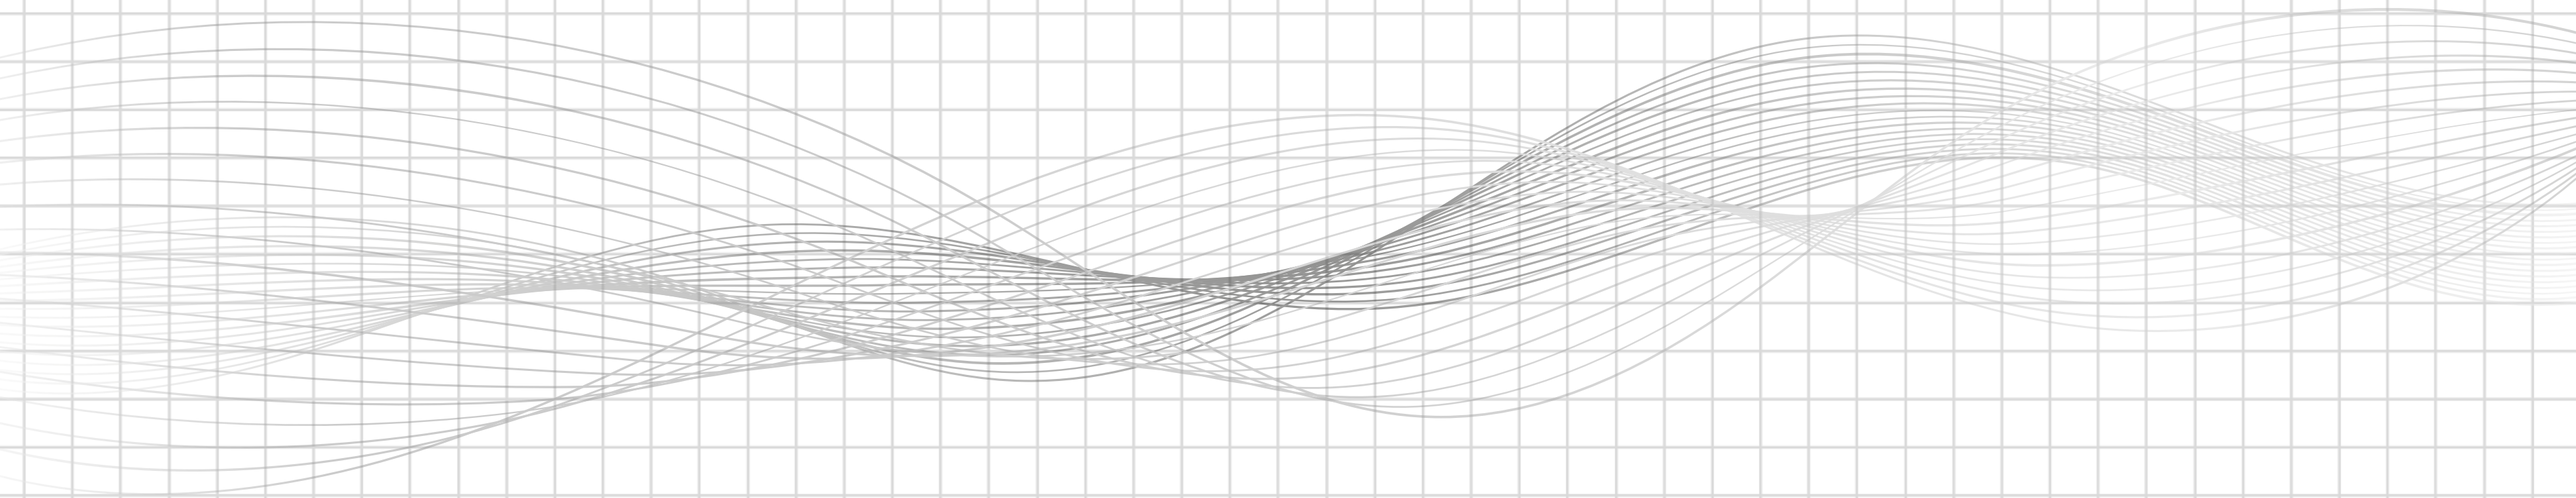
- Evolução anual das notas e do IIE, de 2014 a 2023
- Comparação entre períodos: pré-pandemia (2014-2019), pandemia (2020-2021) e pós-pandemia (2022-2023)
- Crescimento ou redução do gap público-privado
- Variação ano a ano da presença




DIMENSÃO
Dim_Tempo
PK sk_tempo
ano
periodo (pré-pandemia · pandemia · pós)
1
N
FATO
Fato_Desempenho_ENEM
FK sk_tempo
FK sk_localidade
FK sk_rede
FK sk_perfil
M nota_cn · nota_ch
M nota_lc · nota_mt
M nota_redacao
M nota_media
Grão: 1 participante concluinte presente nas 4 provas, por ano
≈ 720 mil linhas/ano
FATO
Fato_Infraestrutura
FK sk_tempo
FK sk_localidade
FK sk_rede
DD co_entidade (escola)
M in_biblioteca
M in_lab_informatica
M in_lab_ciencias
M in_quadra
M iie
M qt_mat_med · qt_doc_med
Grão: 1 escola com ensino médio em atividade, por ano
≈ 30 mil linhas/ano
FATO
Fato_Municipio
FK sk_tempo
FK sk_localidade
M pib_mil_reais
M pib_real
M populacao *
M pib_per_capita_real *
Grão: 1 município por ano
5.570 linhas/ano
DIMENSÃO
Dim_Perfil
PK sk_perfil
sexo
cor_raca
faixa_etaria
faixa_renda
escolaridade_pai
escolaridade_mae
1 N
DIMENSÃO
Dim_Rede
PK sk_rede
dependencia_adm
tipo_rede
localizacao
dependência → pública/privada
urbana / rural
N 1
1 N
DIMENSÃO
Dim_Localidade
PK sk_localidade
co_municipio_ibge
no_municipio
sg_uf · no_uf
no_regiao
município → UF → região
Tabela fato
Dimensão
PK chave primária
FK chave estrangeira
M medida
DD dimensão degenerada
* a calcular (população pendente)

Arquitetura inicial da solução de BI.

Fontes (INEP em CSV, IBGE via API SIDRA) → Extração em Python → camada bruta → transformação com pandas/DuckDB → camada tratada em Parquet → Data Warehouse (DuckDB ou PostgreSQL) → ferramenta de BI (Power BI ou Metabase)



Status e próximos passos

Concluído: seleção e perfilamento das bases, teste de integração, extração do PIB, definição dos KPIs e do modelo

Pendente: população e PIB per capita, extração da série completa 2014-2023

Próxima etapa: ETL e carga do DW